

Классификация изображений (распознавание рукописных цифр)

Семинар в БГУ 11 сентября 2012 года

Содержание презентации

- Почему распознавание рукописных цифр
- Описание данных
- Предварительный анализ данных. Визуализация
- Уменьшение размерности данных для визуализации
- Классификация
- Уменьшение размерности данных для классификации
- Демонстрационное видео



-	A.6				1 11 1	010
Дата посеще-	на дому	Жалобы больного, объективны болезни, подписи вра		Назначения и отметки о выдаче листка нетрудоспособности	· ng	up in
ния	(вписать)	1	recet		MEHERINA VAN	1, ren B, c oul 14943
	10	1 -00			1011 1100	1 5 1012 HE 1427 6
-		Coce	celece	e all	10000	EL 412 1075
_				uece	1 20	61×10× 1018
					when	1, ren 13,6 elle 149,7 2, 61 4,5 × 1912 Hb 149,7 2, 61 × 10 + 5 10 + 5 1 4/10 been 1018
		week	uceel		C-	1/3020
			un or		петопаций ///	not epulos
			mu		Cont. De	et up mulipanella
			unce			11 09 1
		A STATE OF THE PARTY OF THE PAR	muce			· Quene sequency,
-		nu	nue		4 160.	порионострине
		0-	SEL COMP	2.2.1-		
		2/100	ulul	un		ans, 1,5% PP
1			idu	27		eryum.
				nuny	0100	en meparus v 5
				nuly	i com.	
			0 0	. 11-0		unappros
			6 h	cop/her	CET.	1996)
1/20	11 , 0	estague por				wastern ner process
auer.	To mio	y mero color, x		231.		we were the same of the
tike	9 DORBA	TRABARO !	C	7 - 7 -		The line for
11-81	pri cu	N 200-20180		N. International Control		vol in linker
		351-84 01 3/10		1		Sper hyon
46/10	Jerua	ABRUN, MEXPERCE	he	callot		oper 10 jour
0 11	MORAL .	centhabuser				- opun
Le	washe	ABLUS.	2,	o xuel	lel.	The same of the sa
			30	e proces		melinen
					_	- fre ust
			no	our cal	1.	N Sun 18/5
			57	gus cel		- 11
			10			

108 Coce much much much much much much much much	REDUCTION DISTRICTS AND THE PROPERTY OF THE PR	MEHRENN BARY LINES LOVES C- REDOBAHUM NE	SM63p of LOD
en en	un delle	el 160.	eners of surgery, and of the surgery and of
Third calfages food, a green apraise careers, a sport on a reading, a special on a reading. I shall not be a special on a	b kep/ker 231. neaest 310 xues nique cee	eller.	housen net porte in the sol on fresh for a fresh for a fresh for a fresh for a fresh fresh for a fresh

Дата юсеще- ния	Амбулатор. на дому (вписать)	Жалобы больного, объективные данные, течение и диагноз болезни, подлиси врачей и консультантов	Назначения и отметки о выдаче листка нетрудоспособности
- 1	1	. Trelle	
	10	Couleecco	· ·
		mulli a	
		anne	
		your or	
		mm	, , ,
		Cuma	
		mune	
		munue	
		Mulled	une
		2 du	9 7
		2000	

Дата осеще- ния	Амбулатор. на дому (вписать)	Жалобы больного, объективные данные, течение и диагноз болезни, подписи врачей и консультантов	Назначения и отметки о выдаче листка нетрудоспособности
- 1	1	. Freele	
	10	Couleeuce	1 cells
		mullia	
		anne une	
		mun or	
		anna	,,,
		munic	
		mun ue	
		Mulled	eces
		2 de	9

Сосисим или пилим месе семишеее тип же слишишь мимими

Фглиссоесеев мля

Дата посеще- ния	Амбулатор. на дому (вписать)	Жалобы больного, объективные данные, течение и диагноз болезни, подлиси врачей и консультантов	Назначения и отметки о выдаче листка нетрудоспособности
- 1	1	, frielle	
	10	Course	
		muun	
		welle cell	
		your on	
		mm	
		comme	
		munu	
		mune	
		Mulled	eces
		i delle	

Били Соитии инь Пили и мясо шиш шее тип янь **ТИТЯ** СЛИПЛИСЬ чтим мясо ишемия зриши ось я илия

N₂3

Дата осеще- ния	Амбулатор. на дому (вписать)	Жалобы больного, объективные данные, течение и диагноз болезни, подписи врачей и консультантов	Назначения и отметки о выдаче листка нетрудоспособности
- 1	1	. freele	
	10	Couleeuce	, and
		mulli a.	ueer.
		muua	
		mun or	
		mun	
-		anna	
		munce	
		mun ue	
	-	2 Mulling	ece
		2 Mulling	9

Клею.

Солнечный инь.

Жили ж лень.

Шишки

Жми янь.

Тили.

Сплин мы.

Мишки.

з. Ргилавеев

я — лис

Дата Амбул посеще- ния впис	ому ать)	ей и консультантов	Назначения и отметки о выдаче листка нетрудоспособности	We work the	opra
11	01	eece	cepto	My Bur	en 45 -1912 143,73 (1×10 - 1018
	mul	un an	elle elle	<u> </u>	is endormen
	sone	un ce	elle elle	el 160.	appenent pp
of ces affer on selection of the selecti	existague sono esta esta esta esta esta esta esta esta	6 h	en/her 231. cellot o xuel	eles.	homon ner home with all for the form

Описание данных

Данные подготовлены

- Цифры локализованы, центрированы, нормированный размер
 - готовые алгоритмы из популярных библиотек обработки изображений (OpenCV, ImageJ, AForge.NET)
- Размер одной цифры 28×28 пикселов, 256 оттенков серого
- ▶ Весь набор данных в текстовом файле, формат csv
- Первый столбец обозначения классов



Описание данных

lab p	ixe	oixe	oixe	ріхє	ріхє	pixe	pixe	ріхє	ріхє	pixe	pixe	ріхє	ріхє	ріхє	pixe	pixe	ріхє	ріхє	ріхє	pixe	oixe	oixe	pixep	oixe	oixe	oixe	oixe	oixe	pixe	ріхє
1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0		188		94	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	18	30	137	137	192	86	72	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
1	0	0	0	0	0	0	0	0	3	141	139	3	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
4	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	1	25	130	155	254	254	254	157	30	2	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	3	141	202	254	193	44	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
7	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
3	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
5	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
3	0	0	0	5	60	136	136	147	254	255	199	111	18	9	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
8	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
9	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
3	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	64	128
3	0	0	0	0	0	0	101	222	253	253	192	113	88	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
2	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	144	254	130	0	0	0	0	0	0	0	0	0	0	0	0	0	0
7	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
5	0	0	0	0	0	4	29	66	141	141	216	253	203	255	253	253	153	13	0	0	0	0	0	0	0	0	0	0	0	0
8	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
6	0	0	0	0	0	0	0	0	0	0	0	0	0	0		189	254	230	18	0	0	0	0	0	0	0	0	0	0	0
2	0	0	0	0	0	0	0	0				253	170	63	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	5	55	138	138	74	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0



Предварительный анализ данных. Визуализация

-	132	1550	16		1576	1500	16	15	4576	1550	16		1576	1500	16	15	1576
0	0	0	0	0	0	0	0	9	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	41	149	156	179	254	254	201	119	46	0	0	0
0	0	0	0	13	147	241	253	253	254	253	253	253	253	245	160	0	0
9	0	0	31	224	253	253	180	174	175	174	174	174	174	223	247	145	6
9	0	7	197	254	253	165	2	0	0	0	0	0	0	12	102	184	16
9	0	152	253	254	162	18	0	9	9	9	0	0	0	9	0	0	0
0	0	235	254	158	15	0	0	0	0	0	0	0	0	0	0	0	0
0	74	250	253	15	0	0	0	16	20	19	0	0	9	0	0	0	0
7	199	253	253	0	0	25	130	235	254	247	145	6	0	0	0	0	0
20	253	253	177	100	219	240	253	253	254	253	253	125	0	9	0	0	0
5	193	253	253	254	253	253	200	155	155	238	253	229	23	0	0	0	0
9	61	249	254	241	150	30	0	9	0	215	254	254	58	9	0	0	0
0	0	36	39	30	0	0	0	0	0	214	253	234	31	0	0	0	0
0	0	0	0	0	0	9	0	9	41	241	253	183	0	9	0	0	0
0	0	0	0	0	0	0	0	0	201	253	253	102	0	0	0	0	0
0	0	0	0	0	0	0	0	114	254	253	154	5	0	0	0	0	0
0	0	0	0	0	0	0	62	254	255	241	30	0	0	0	0	0	0
0	0	0	0	0	10	118	235	253	249	103	0	0	0	0	0	0	0
0	55	81	0	102	211	253	253	253	135	0	0	0	0	0	0	0	0
0	79	243	234	254	253	253	216	117	0	0	0	0	0	0	0	0	0
9	48	245	253	254	207	126	27	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	9	0

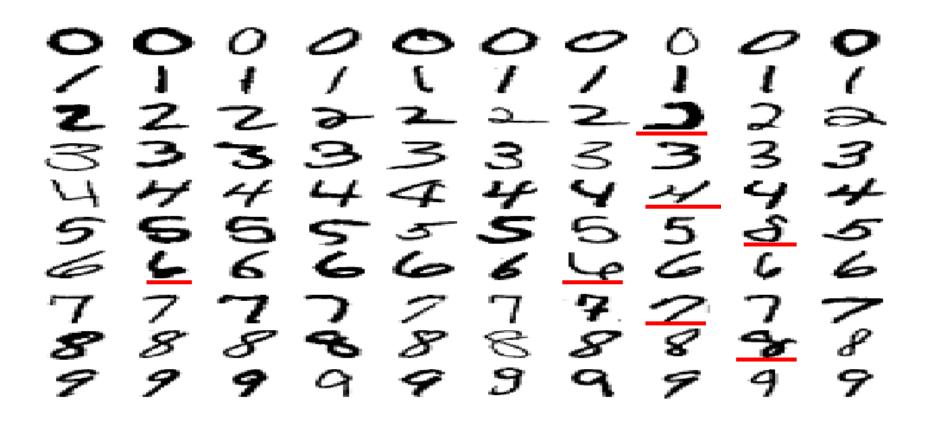


Предварительный анализ данных. Визуализация





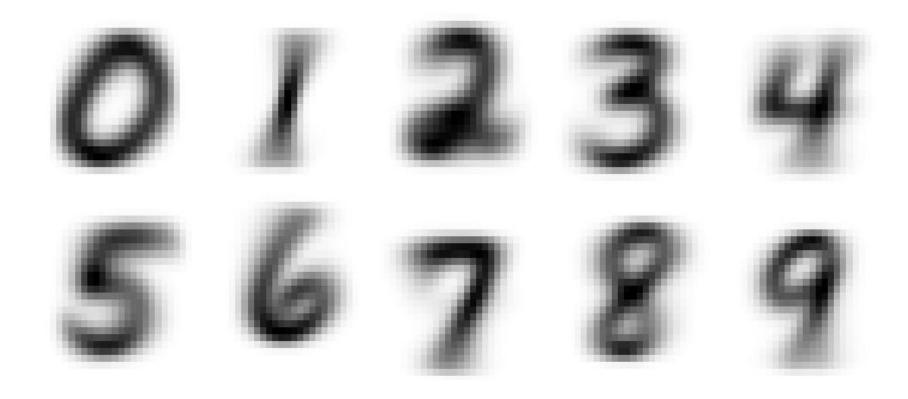
Предварительный анализ данных. Визуализация





Предварительный анализ данных. Визуализация

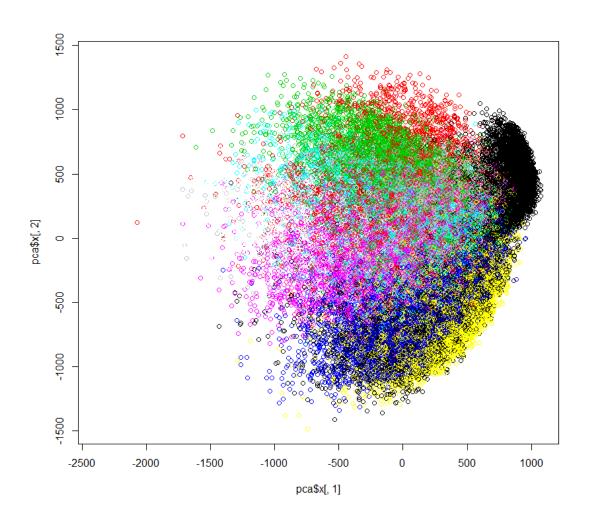
0	1	2	3	4	5	6	7	8	9
3286	3715	3360	3462	3209	3062	3296	3545	3268	3332



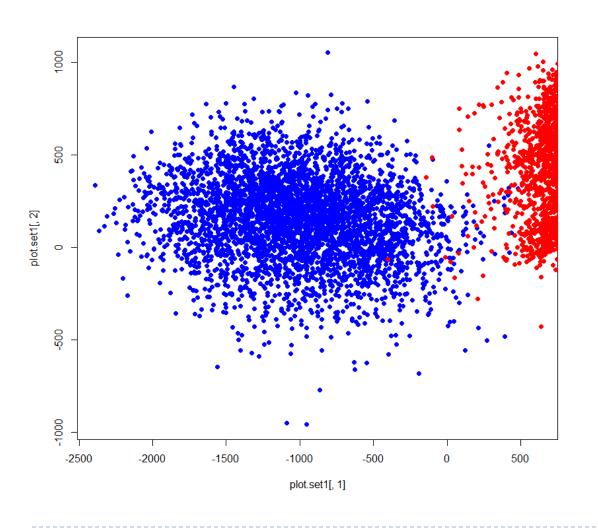


- Взаимное расположение классов на плоскости
 - длина одного вектора-признака 784 = 28×28 элементов
 - нужно оставить только две координаты, но максимально точно сохранить взаимное расположение векторов
 - методы уменьшения размерности данных
 - PCA, метод главных компонент
 - ▶ SVD, сингулярное разложение
 - ▶ MDS, многомерное шкалирование
- ▶ Признаки в 2D, 3D





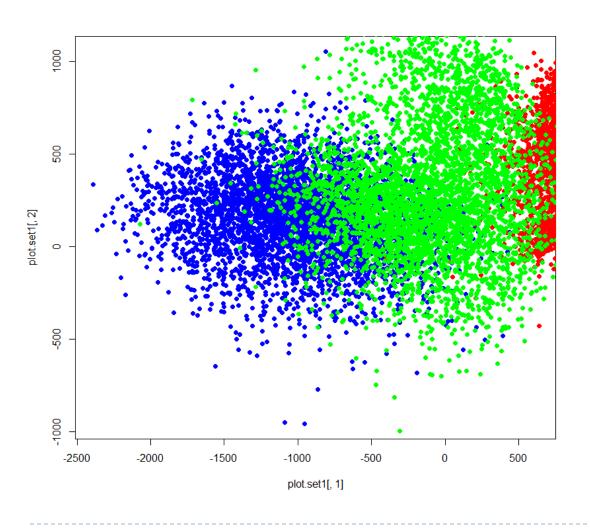




0 — синий цвет

1 — красный цвет





- 0 синий цвет
- 1 красный цвет
- 2 зелёный цвет



Классификация

- На тестовых данных с известными метками классов тренируется классификатор
 - метод k ближайших соседей
 - случайный лес
- Для неизвестных данных без меток классификатор принимает решение о принадлежности к одному из классов
 - метод k ближайших соседей, точность 96.338%
 - случайный лес, 96.645%
 - лучший результат для этих данных 99.471%

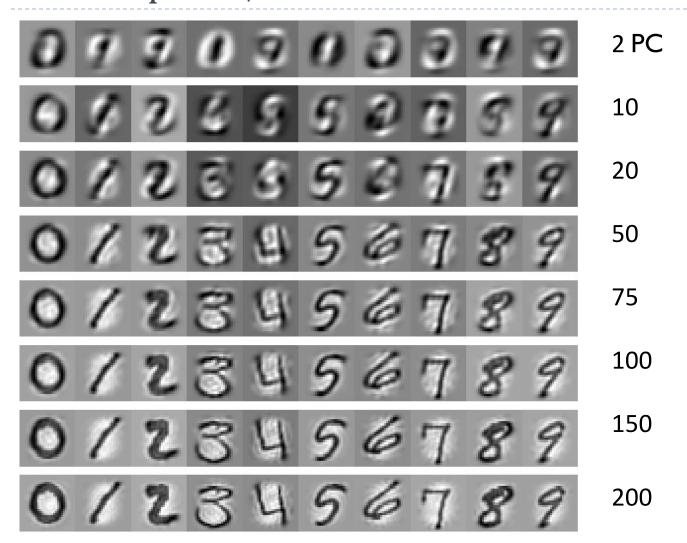


Уменьшение размерности данных для классификации

- Большие данные требуют много вычислительных ресурсов
 - процессорное время
 - оперативная память
- Матрица 42000×784, файл 73 мегабайта, оперативная память во время классификации около 2 гигабайт
- Что делать
 - предоставить больше ресурсов (параллелизация, облачные вычисления)
 - преобразовать исходные данные с наименьшими потерями



Уменьшение размерности данных для классификации





Уменьшение размерности данных для классификации

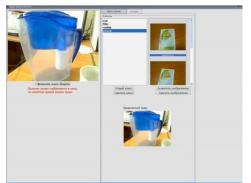
	10	154	200	784
К ближайших	92.233	96.527	96.527	96.338
Случайный лес	90.667	94.247	94.034	96.645

- Не всегда чем больше признаков, тем лучше
- Важно правильно выбрать признаки, классификатор и его параметры



Демонстрационное видео

- Процедура классификации для разных задач
 - извлечение признаков из изображения
 - преобразование признаков, выбор классификатора и подбор оптимальных параметров
 - использование обученного классификатора
 - распознавание рукописных цифр
 - детектирование новообразований на КТ лёгких
 - поиск объектов в комнате









Дополнительные материалы и ссылки

- Материалы этого доклада: презентация, данные, изображения, скрипты, видео-демонстрация
 - https://github.com/ihar/BSU-Workshop-2012
- Язык программирования для статистической обработки и программная среда вычислений R
 - http://www.r-project.org/
- База рукописных цифр и соревнование по их распознаванию
 - http://www.kaggle.com/c/digit-recognizer

